

最优化技术

孙志强

第三章 无约束非线性优化问题

目录

1

3.1 预备知识

2

3.2 迭代和一维搜索

3


3.3 无约束优化问题的梯度方法

4

总结


示例1

二元函数 $f(x_1, x_2) = x_1^2 + x_2^2$ 的图形为一个抛物面：




示例2

二元函数 $f(x_1, x_2) = x_1^2 + x_2^2$ 的水平集为：




示例2

二元函数 $f(x_1, x_2) = x_1^2 + 2x_2^2$ 的图形也是一个抛物面：



示例2

二元函数 $f(x_1, x_2) = x_1^2 + 2x_2^2$ 的水平集为：



函数值最快增长方向

函数 f 在方向 d 上的增长率为方向导数

$$\frac{\partial f}{\partial d} = \nabla f(x)^T d = \langle \nabla f(x), d \rangle \quad (1)$$

令 $\|d\| = 1$, 利用柯西-施瓦茨不等式, 可得

$$\langle \nabla f(x), d \rangle \leq \| \nabla f(x) \| \| d \| = \| \nabla f(x) \| \quad (2)$$

函数值最快增长方向

函数 f 在方向 d 上的增长率为方向导数

$$\frac{\partial f}{\partial d} = \nabla f(x)^T d = \langle \nabla f(x), d \rangle \quad (1)$$

令 $\|d\| = 1$, 利用柯西-施瓦茨不等式, 可得

$$\langle \nabla f(x), d \rangle \leq \| \nabla f(x) \| \| d \| = \| \nabla f(x) \| \quad (2)$$

令 $d = \nabla f(x) / \| \nabla f(x) \|$, 则有

$$\langle \nabla f(x), \nabla f(x) / \| \nabla f(x) \| \rangle = \| \nabla f(x) \| \quad (3)$$

因此, 梯度 $\nabla f(x)$ 就是函数 f 在 x 处增长最快的方向. 反之, 梯度的负方向 $-\nabla f(x)$ 就是函数 f 在 x 处下降最快的方向.

迭代

令 $x^{(0)}$ 表示集合 Ω 中的某个点, $x^{(0)} - \alpha \nabla f(x^{(0)})$ 表示另外一个点. 由Taylor公式可得

$$f(x^{(0)} - \alpha \nabla f(x^{(0)})) = f(x^{(0)}) - \alpha \|\nabla f(x^{(0)})\|^2 + o(\alpha) \quad (4)$$

如果 $\nabla f(x^{(0)}) \neq 0$, 总有一个足够小的 $\alpha > 0$, 使得

$$f(x^{(0)} - \alpha \nabla f(x^{(0)})) < f(x^{(0)}) \quad (5)$$

迭代

这样一来，就可以得到一个新点

$$x^{(1)} = x^{(0)} - \alpha \nabla f(x^{(0)})$$

满足

$$f(x^{(1)}) < f(x^{(0)})$$

迭代

这样一来，就可以得到一个新点

$$x^{(1)} = x^{(0)} - \alpha \nabla f(x^{(0)})$$

满足

$$f(x^{(1)}) < f(x^{(0)})$$

循环往复，是否就可以得到一组 x ，使得目标函数的值逐渐缩小，一直达到最优解呢？

迭代

这样一来，就可以得到一个新点

$$x^{(1)} = x^{(0)} - \alpha \nabla f(x^{(0)})$$

满足

$$f(x^{(1)}) < f(x^{(0)})$$

循环往复，是否就可以得到一组 x ，使得目标函数的值逐渐缩小，一直达到最优解呢？这就是迭代的思路。


用迭代来求解优化问题

基本思路

- 1 从可行域中选择一个初始点 $x^{(0)}$, $k = 0$;
- 2 构造搜索方向 d_k , 使得目标函数的值能够沿着该方向下降;
- 3 构造搜索步长 α_k , 以 $x^{(k)}$ 为起点, 沿着搜索方向 d_k 寻找合适的步长 $\alpha_k > 0$, 使得目标函数值能够最大程度的下降;
- 4 按照迭代格式 $x^{(k+1)} = x^{(k)} + \alpha_k d_k$ 求出下一个迭代点 $x^{(k+1)}$, 若 $x^{(k+1)}$ 已经满足终止条件, 停止迭代; 否则, 令 $k = k + 1$, 转第2步。

用迭代来求解优化问题

令 $x^{(k)}$ 为第 k 步迭代的迭代点, $x^{(k+1)}$ 为需要寻找的下一个迭代点.



有 $\Delta x_k = x^{(k+1)} - x^{(k)} = \alpha_k d_k$, $f(x^{(k+1)}) < f(x^{(k)})$. α_k 为步长, d_k 为下降方向. 那么应该如何确定 α_k 和 d_k 呢?

确定步长

假定下降方向 d_k 已经确定，那么应该如何确定步长 α_k ? 令

$$\varphi(\alpha) = f(x^{(k+1)}) = f(x^{(k)} + \alpha d_k)$$

那么 $\varphi(\alpha) : \mathbb{R} \rightarrow \mathbb{R}$ 就是一个关于 α 的单值函数. 寻找一个合适的 α^* 使得 $\varphi(\alpha)$ 最小，等价于使得函数 $f(x^{(k+1)})$ 最小. α^* 就是要找的 α_k .

确定步长的注意事项

对于无约束问题，步长完全可以按照以上方式进行选择，因为 $x^{(k+1)}$ 无论如何都不会超出可行域。

对于有约束问题，除了使得 $f(x^{(k+1)})$ 最小化之外，还必须考虑 $x^{(k+1)}$ 能否位于可行域内。

一维搜索的性质

很明显, 函数 $\varphi(\alpha)$ 在 α^* 处的导数为0.

$$\varphi'(\alpha) = 0 \quad (6)$$

一维搜索的性质

很明显, 函数 $\varphi(\alpha)$ 在 α^* 处的导数为0.

$$\varphi'(\alpha) = 0 \quad (6)$$

为什么?

一维搜索的性质

很明显, 函数 $\varphi(\alpha)$ 在 α^* 处的导数为0.

$$\varphi'(\alpha) = 0 \quad (6)$$

为什么? 一阶必要条件。

一维搜索的性质

很明显, 函数 $\varphi(\alpha)$ 在 α^* 处的导数为0.

$$\varphi'(\alpha) = 0 \quad (6)$$

为什么? 一阶必要条件。

$$\varphi'(\alpha) = \nabla f(x^{(k+1)})^T d_k = 0 \quad (7)$$

这意味着什么?

一维搜索的性质

很明显, 函数 $\varphi(\alpha)$ 在 α^* 处的导数为0.

$$\varphi'(\alpha) = 0 \quad (6)$$

为什么? 一阶必要条件。

$$\varphi'(\alpha) = \nabla f(x^{(k+1)})^T d_k = 0 \quad (7)$$

这意味着什么? 按照一维搜索方法确定步长, 使得 $x^{(k)}$ 处的下降方向与 $x^{(k+1)}$ 处目标函数的梯度正交。

一维搜索

一维搜索又称为直线搜索，因为只有一个变量。最为简单的求解方法就是直接对其进行求导，令 $\varphi'(\alpha) = 0$ ，求解可得到对应的步长。

一维搜索

一维搜索又称为直线搜索，因为只有一个变量。最为简单的求解方法就是直接对其进行求导，

令 $\varphi'(\alpha) = 0$ ，求解可得到对应的步长。

当目标函数形式比较复杂时， $\varphi'(\alpha)$ 是一个非线性函数，求解存在困难。在计算机发展水平较低的年代，研究人员推出一些数值算法，能够较快的搜索得到近似解。实际上，计算机内部的求解过程也是这么实现的。这些方法包括

- 1 黄金分割法
- 2 Fibonacci数列法
- 3 牛顿法
- 4 割线法

无约束优化问题的下降方向

对于无约束问题，任意方向都可能是下降方向。但下降方向有哪些要求呢？

无约束优化问题的下降方向

对于无约束问题，任意方向都可能是下降方向。但下降方向有哪些要求呢？

定义

如果存在一个正数 $\delta > 0$ 使得函数 $f(x)$ 对于所有的 $\alpha \in (0, \delta)$ 都有

$$f(x^* + \alpha d) < f(x^*)$$

成立，则 d 为点 x^* 处的一个下降方向。

无约束优化问题的下降方向

对于无约束问题，任意方向都可能是下降方向。但下降方向有哪些要求呢？

定义

如果存在一个正数 $\delta > 0$ 使得函数 $f(x)$ 对于所有的 $\alpha \in (0, \delta)$ 都有

$$f(x^* + \alpha d) < f(x^*)$$

成立，则 d 为点 x^* 处的一个下降方向。

下降方向的性质

如果 $\nabla f(x^*)^T d < 0$ 成立， d 为点 x^* 处的一个下降方向。

梯度下降算法

前面已经提到过，点 x^* 处梯度负方向 $-\nabla f(x^*)$ 是该点处函数下降最快的方向。因此， $-\nabla f(x^*)$ 可以直接作为下降方向。迭代算法为

$$x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)}) \quad (8)$$

这被称为梯度下降算法. 随着搜索的进行，梯度持续变化，达到最优值时，梯度变为零. 在所有的梯度下降方法中，最速下降法最为常用.

最速下降法算法

算法步骤

- 1 选择初始点 x_0 ，给定停止精度 $\epsilon > 0$ ，令 $k = 0$;
- 2 计算目标函数的梯度 $\nabla f(x^{(k)})$ 。如果 $\|\nabla f(x^{(k)})\| \leq \epsilon$ ，停止迭代， $x^{(k)}$ 即为最终结果；否则，转下一步；
- 3 构造下降方向（梯度反方向） $d_k = -\nabla f(x^{(k)})$;
- 4 进行一维搜索，依据

$$f(x^{(k)} + \alpha_k d_k) = \min f(x^{(k)} + \alpha d_k)$$

求出步长 α_k ；令 $x^{(k+1)} = x^{(k)} + \alpha_k d_k, k = k + 1$ ，转第2步。


算法特性

特性

令 $\{x^{(k)}\}$ 表示目标函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的下降方向序列, 则有 $x^{(k+1)} - x^{(k)}$ 和 $x^{(k+2)} - x^{(k+1)}$ 相互正交.

提示: $\nabla f(x^{(k+1)})^T d_k = 0$.

特性示意



前期收敛速度快，越接近最优解，收敛越慢，甚至会出现“锯齿”现象。

停止规则

理论上讲，在 $\nabla f(x^{(k)}) = 0$ 之前，迭代总是持续进行。
但是，这一条件并不能直接作为停止规则。

停止规则

理论上讲，在 $\nabla f(x^{(k)}) = 0$ 之前，迭代总是持续进行。但是，这一条件并不能直接作为停止规则。常用的停止规则为：

1 $\| \nabla f(x^{(k)}) \| < \epsilon$, ϵ 为预先设定的阈值

2 $|f(x^{(k+1)}) - f(x^{(k)})| < \epsilon$

3 $\| x^{(k+1)} - x^{(k)} \| < \epsilon$

4 $\frac{|f(x^{(k+1)}) - f(x^{(k)})|}{\max(1, |f(x^{(k)})|)} < \epsilon$

5 $\frac{\|x^{(k+1)} - x^{(k)}\|}{\max(1, \|x^{(k)}\|)} < \epsilon$

示例1

$$\min f(x_1, x_2, x_3) = (x_1 - 4)^4 + (x_2 - 3)^2 + 4(x_3 + 5)^4 \quad (9)$$

起始点为 $x^{(0)} = [4, 2, -1]^T$.

示例1

$$\min f(x_1, x_2, x_3) = (x_1 - 4)^4 + (x_2 - 3)^2 + 4(x_3 + 5)^4 \quad (9)$$

起始点为 $x^{(0)} = [4, 2, -1]^T$.

$$\nabla f(x) = [4(x_1 - 4)^3, 2(x_2 - 3), 16(x_3 + 5)^3]^T$$

$$\nabla f(x_0) = [0, -2, 1024]^T$$

$$\varphi(\alpha) = (2\alpha - 1)^2 + 4(1024\alpha - 4)^4 \Rightarrow \alpha_0 = 3.967 \times 10^{-3}$$

$$x^{(1)} = [4.000, 2.008, -5.062]^T$$

$$x^{(2)} = [4.000, 3.000, -5.060]^T$$

$$x^{(3)} = [4.000, 3.000, -5.002]^T$$

示例2

利用最速下降法求二次型目标函数的最优解

$$f(x) = \frac{1}{2}x^T Qx - b^T x \quad (10)$$

$Q \in \mathbb{R}^{n \times n}$ 是一个对称正定矩阵.

示例2


利用最速下降法求二次型目标函数的最优解

$$f(x) = \frac{1}{2}x^T Qx - b^T x \quad (10)$$


$Q \in \mathbb{R}^{n \times n}$ 是一个对称正定矩阵.

$$\begin{aligned}\alpha_k &= \frac{g_k^T g_k}{g_k^T Q g_k} \\ g_k &= \nabla f(x^{(k)}) = Qx^{(k)} - b \\ x^{(k+1)} &= x^{(k)} - \alpha_k g_k\end{aligned}$$

收敛性



收敛性



总结

- 1 利用数值方法迭代求解优化问题的基本思路;
 - ▶ 下降方向
 - ▶ 步长
- 2 梯度下降方法(最速下降法)

作业

- 1 8.6(a)(b) [考察二次型和正定矩阵]
- 2 8.18