

最优化技术

孙志强

第三章 无约束非线性优化问题

内容

1 3.7 共轭梯度法

- 3.7.1 预备知识
- 3.7.2 共轭方向法
- 3.7.3 共轭梯度法确定共轭方向
- 3.7.4 共轭梯度法应用到非二次型问题

2 3.8 单纯形替换法

- 3.8.1 预备知识
- 3.8.2 几何解释
- 3.8.3 算法步骤

有关定义和定理

Q共轭的定义10.1 (120页)

Q 是一个 $n \times n$ 的对称正定矩阵. 如果对于所有的 $i \neq j$, 都有 $d_i^T Q d_j = 0$ 成立, 则方向 $d_0, d_1, \dots, d_m$ 称为 Q - 共轭的.

有关定义和定理

Q共轭的定义10.1 (120页)

Q 是一个 $n \times n$ 的对称正定矩阵. 如果对于所有的 $i \neq j$, 都有 $d_i^T Q d_j = 0$ 成立, 则方向 $d_0, d_1, \dots, d_m$ 称为 Q -共轭的.

Q共轭的引理10.1 (120页)

Q 是一个 $n \times n$ 的对称正定矩阵. 如果

$$d_0, d_1, \dots, d_k \in \mathbb{R}^n, k \leq n - 1$$

全部非零且是 Q -共轭的, 则它们是线性无关的.

基本思想

二次型函数

$$f(x) = \frac{1}{2}x^T Qx - x^T b \quad (1)$$

有一个全局最优解 $x = Q^{-1}b$.

基本思想

二次型函数

$$f(x) = \frac{1}{2}x^T Qx - x^T b \quad (1)$$

有一个全局最优解 $x = Q^{-1}b$.

基本步骤

给定一个搜索的初始点 $x^{(0)}$ 和一组Q-共轭方向 $d_0, d_1, \dots, d_{n-1}$; 对于 $k \geq 0$

$$g_k = \nabla f(x^{(k)}) = Qx^{(k)} - b; \quad \alpha_k = -\frac{g_k^T d_k}{d_k^T Q d_k}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k d_k$$

共轭方向法特性

定理10.1(121页)

共轭方向法能够在 n 步之内收敛到最小值，无论初始点 $x^{(0)}$ 如何选择。

共轭方向法特性

定理10.1(121页)

共轭方向法能够在 n 步之内收敛到最小值，无论初始点 $x^{(0)}$ 如何选择。

这是共轭方向法的一个重要特性。除此之外，相对于牛顿法，共轭方向法的另外两个特点是：

- 1 不需要计算黑塞矩阵
- 2 不需要计算并存储逆矩阵，节省存储空间，有利于提高计算效率

共轭方向法特性

定理10.1(121页)

共轭方向法能够在 n 步之内收敛到最小值，无论初始点 $x^{(0)}$ 如何选择。

这是共轭方向法的一个重要特性。除此之外，相对于牛顿法，共轭方向法的另外两个特点是：

- 1 不需要计算黑塞矩阵
- 2 不需要计算并存储逆矩阵，节省存储空间，有利于提高计算效率

但是，如何事先给定共轭方向？

方法概述

共轭梯度法无需事先给定共轭方向，而是在搜索过程中逐渐确定共轭方向。基本思路为利用梯度反方向作为初始搜索方向，基于一维搜索确定搜索步长；然后根据Q-共轭的特性确定第二次迭代的搜索方向，将第二次搜索方向表示为目标函数在该迭代点处的梯度与上一个搜索方向的线性组合，确定了线性组合的系数之后即可确定搜索方向，依此类推，每次迭代都可以确定接下来的搜索方向，直到最优值。

算法步骤

- 1 令 $k = 0$; 选择搜索的初始点 $x^{(0)}$.
- 2 $g_0 = \nabla f(x^{(0)})$. 如果 $g_0 = 0$, 停止搜索; 否则, 令 $d_0 = -g_0$.
- 3 $\alpha_k = -\frac{g_k^T d_k}{d_k^T Q d_k}$.
- 4 $x^{(k+1)} = x^{(k)} + \alpha_k d_k$.
- 5 $g_{k+1} = \nabla f(x^{(k+1)})$. 如果 $g_{k+1} = 0$, 停止搜索.
- 6 $\beta_k = \frac{g_{k+1}^T Q d_k}{d_k^T Q d_k}$.
- 7 $d_{k+1} = -g_{k+1} + \beta_k d_k$.
- 8 令 $k = k + 1$; 返回第3步.

算法特性

性质

共轭梯度法产生的搜索方向是Q-共轭的

算法特性

性质

共轭梯度法产生的搜索方向是Q-共轭的
可利用数学归纳法进行证明。

示例

利用共轭梯度法求二次型目标函数

$$f(x) = \frac{1}{2}x^T Qx - x^T b$$

的最优解

$$Q = \begin{pmatrix} 3 & 0 & 1 \\ 0 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 3 \\ 0 \\ 1 \end{pmatrix}$$

M文件

```
function history=cgm(Q,b,x0,threshold)
%初始化, x b都表示为行向量的形式
x=x0;
grad=Q*x0'-b'; %梯度方向
d=-grad; %梯度的负方向
alpha=-grad'*d/(d'*Q*d); %步长
history.x=x0;
history.fval=0.5*x*Q*x'-b*x';
history.grad=grad';
history.d=d';
while (norm(grad)>threshold)
    x=x+alpha*d'; %产生一个新的x;
    grad=Q*x'-b'; %在这个新的x下产生梯度
    beta=grad'*Q*d/(d'*Q*d); %利用这个新梯度和老方
    向产生beta
```

结果

No.	x	Gradient	fval	Descent Direction
0	$(0, 0, 0)^T$	$(-3, 0, 1.0000)^T$	0	$(3, 0, 1)^T$
1	$(0.8333, 0, 0.2778)^T$	$(-0.2222, 0.5556, 0.6667)^T$	-1.3889	$(0.4630, -0.5556, -0.5864)^T$
2	$(0.9346, -0.1215, 0.1495)^T$	$(-0.0467, -0.1869, 0.1402)^T$	-1.4766	$(0.0795, 0.1476, -0.1817)^T$
3	$(1.0000, 0.0000, 0.0000)^T$	$(0.0000, 0.0000, 0.0000)^T$	-1.5000	$(0.0000, 0.0000, 0.0000)^T$

改进公式

“ Q 共轭”意味着需要正定矩阵 Q ，对于非最小二乘问题，矩阵 Q 不可得。在共轭梯度算法步骤中， α_k 采用一维搜索确定，只有 β_k 的确定需要用到矩阵 Q 。如果可以替换掉 Q ，就可以将这一算法推广到非二次型问题。

$$\beta_k = \frac{g_{k+1}^T (g_{k+1} - g_k)}{d_k^T (g_{k+1} - g_k)} \quad \text{Hestenes-Stiefel公式}$$

$$\beta_k = \frac{g_{k+1}^T (g_{k+1} - g_k)}{g_k^T g_k} \quad \text{Polak-Ribiere公式}$$

$$\beta_k = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k} \quad \text{Fletcher-Reeves公式}$$

概述

由Spendley、Hext和Himsworth于1962年提出；1965年，Nelder和Mead对其进行了改进。相对于前面的牛顿法和拟牛顿法等方法，该方法最大的优势在于避免了求目标函数的梯度和二阶导数。为什么求梯度和二阶导数会比较困难？它们会带来一些什么样的问题？

算法的基本思想

集合迭代的思想

$$S_0 \rightarrow S_1 \rightarrow \dots \rightarrow S_k \rightarrow S_{k+1} \rightarrow \dots$$

S_i 表示单纯形。

下降迭代的思想

使 S_i 中顶点对应的目标函数值下降。

什么是单纯形?

令 $V^0, V^1, \dots, V^n \in R^n$, 如果

$$V^j - V^0, j = 1, 2, \dots, n$$

线性无关, 则 $V^i, i = 0, 1, 2, \dots, n$ 的组合称为由 V^i 构成的单纯形, 记为

$$\begin{aligned} S &= [V^0, V^1, V^2, \dots, V^n] \\ &= \{x | \sum_{j=0}^n \alpha_j V^j, \sum_{j=0}^n \alpha_j = 1, \alpha_j > 0\} \end{aligned}$$


$V^i, i = 0, 1, 2, \dots, n$ 为单纯形 S 的顶点。

单纯形示例


R^1 : 线段



R^2 : 三角形



R^3 : 四面体



如何构造单纯形

给定点 x^0 和正数 δ , 令

$$V^0 = x^0$$

$$V^1 = V^0 + \delta e_1 \quad V^1 - V^0 = \delta e_1$$

$$V^2 = V^1 + \delta e_2 \quad V^2 - V^0 = \delta(e_1 + e_2)$$

$$\dots \quad \dots$$

$$V^n = V^{n-1} + \delta e_n \quad V^n - V^0 = \delta(e_1 + e_2 + \dots + e_n)$$

则 $S = [V^0, V^1, \dots, V^n]$ 构成一个单纯形。

构造单纯形示例

设 $V^0 = (1, 0, 1)^T$, $\delta = 0.5$, 可得

$$V^1 = V^0 + \delta e_1 = (1, 0, 1)^T + 0.5 \times (1, 0, 0)^T = (1.5, 0, 1)^T$$

$$V^2 = V^1 + \delta e_2 = (1.5, 0, 1)^T + 0.5 \times (0, 1, 0)^T = (1.5, 0.5, 1)^T$$

$$V^3 = V^2 + \delta e_3 = (1.5, 0.5, 1)^T + 0.5 \times (0, 0, 1)^T = (1.5, 0.5, 1.5)^T$$

则 $S = [V^0, V^1, V^2, V^3]$ 构成一个单纯形。

初始化和反射步

给定初始的单纯形 $S = [V^0, V^1, V^2, \dots, V^n]$. 设

$$f(V^h) = \max\{f(V^0), f(V^1), \dots, f(V^n)\}$$

$$f(V^l) = \min\{f(V^0), f(V^1), \dots, f(V^n)\}$$

令

$$\bar{V} = \frac{1}{n} \sum_{i \neq h} V^i$$

反射步: $V^r = \bar{V} + \alpha(\bar{V} - V^h)$

V^r : 反射点, α : 反射系数, 一般取 $\alpha = 1$ 。

延伸步

如果 $f(V^r) < f(V^l)$ ，执行延伸步：计算

$$V^e = \bar{V} + \beta(V^r - \bar{V})$$

V^e :延伸点, β :延伸系数, 一般取 $\beta = 2$ 。

若 $f(V^e) < f(V^l)$ ，则用 V^e 代替 V^h ，构成新的单纯形，
否则使用 V^r 代替 V^h ，构成新的单纯形。

收缩步(第一种情形)


对于 $\forall i \neq h$, 有 $f(V^i) \leq f(V^r) \leq f(V^h)$, 则令

$$V^c = \bar{V} + \gamma(V^r - \bar{V})$$

V^c : 收缩点, γ 为收缩系数, 一般取 $\gamma = 0.5$.

如果 $f(V^c) < f(V^h)$, 则用 V^c 取代 V^h , 构成新的单纯形。

收缩步(第一种情形)



收缩步(第二种情形)

如果 $f(V^r) > f(V^h)$, 则令 $V^c = \bar{V} + \gamma(V^h - \bar{V})$.

V^c :收缩点, γ 为收缩系数, 一般取 $\gamma = 0.5$.

如果 $f(V^c) < f(V^h)$, 则用 V^c 取代 V^h ,构成新的单纯形。

棱长减半步

如果 $f(V^c) > f(V^h)$,则执行棱长减半步:

$$V^i = \frac{V^i + V^l}{2}, i = 0, 1, \dots, n$$

$$S_{k+1} = [V^0, V^1, \dots, V^n]$$

步骤1-3

Step 1.(初始步)给定初始点 x^0 ,预设精度 ϵ ,构造初始单纯形

$$S_0 = [V^0, V^1, \dots, V^n], k = 0$$

Step 2.(准备步)计算

$$f(V^h) = \max_{0 \leq i \leq n} f(V^i), f(V^l) = \min_{0 \leq i \leq n} f(V^i), \bar{V} = \sum_{i \neq h} V^i / n$$

Step 3.(反射步)计算

$$V^r = \bar{V} + \alpha(\bar{V} - V^h)$$

如果 $f(V^r) < f(V^l)$,则转Step 4; 否则, 转Step 5。

步骤4-5

Step 4.(延伸步)计算

$$V^e = \bar{V} + \beta(\bar{V} - V^h) = \bar{V} + \beta(V^r - \bar{V})$$

如果 $f(V^e) < f(V^l)[f(V^e) < f(V^r)]$,则

$V^h = V^e, S_{k+1} = [V^0, V^1, \dots, V^n]$,转Step 7; 否则

$V^h = V^r, S_{k+1} = [V^0, V^1, \dots, V^n]$,转Step 7.

Step 5.(收缩步)

(1)如果 $\exists i \neq h$, 使得 $f(V^r) < f(V^i)$,

则 $V^h = V^r, S_{k+1} = [V^0, V^1, \dots, V^n]$,转Step 7.

步骤5

(2)如果 $\forall i \neq h$, 使得 $f(V^i) \leq f(V^r) \leq f(V^h)$, 则 $V^c = \bar{V} + \gamma(V^r - \bar{V})$. 如果 $f(V^c) < f(V^r)$, 则 $V^h = V^c$, $S_{k+1} = [V^0, V^1, \dots, V^n]$, 转Step 7. 否则, 转Step 6.

(3)如果 $f(V^r) > f(V^h)$, 则 $V^c = \bar{V} + \gamma(V^r - \bar{V})$. 如果 $f(V^c) < f(V^r)$, 则 $V^h = V^c$, $S_{k+1} = [V^0, V^1, \dots, V^n]$, 转Step 7. 否则, 转Step 6.

步骤6-7

Step 6.(棱长减半步)计算

$$V^i = \frac{V^i + V^l}{2}, i = 0, 1, \dots, n$$

$S_{k+1} = [V^0, V^1, \dots, V^n]$, 转Step 7.

Step 7.(判断步)计算

$$V = \frac{1}{n+1} \sum_{i=0}^n V^i$$

如果 $\sum_{i=0}^n \|V^i - V\| \leq \epsilon$, 计算结束, 得到

$$x^* = V = \frac{1}{n+1} \sum_{i=0}^n V^i$$

否则, 令 $S_{k+1} = [V^0, V^1, \dots, V^n]$, $k = k + 1$ 转Step 2.

示例

例：试用单纯形替换法求解

$$\min \quad f(x) = (2x_1 - x_2)^2 + x_2^2$$

其中，初始单纯形的顶点为 $V^0 = (-1, 2)^T$. 各系数的取值为 $\alpha = 1, \beta = 2, \gamma = 0.5$.

作业

1 10.2