

最优化技术

孙志强

第四章 线性优化问题

内容

- 1 4.8 内点法
 - 4.8.1 预备知识
 - 4.8.2 中间路径
 - 4.8.3 对偶间隙
 - 4.8.4 内点法基本思路
 - 4.8.5 内点法的具体实现
 - 4.8.6 MATLAB中的内点法

- 2 总结

基本概念

内点法的基本思路是由俄罗斯数学家Karmarkar提出的. 该算法的基本思路为:

- 1: 在可行域的内部逐步趋向于最优解.
- 2: 沿着使目标函数值下降最快的方向进行迭代.
- 3: 对可行域进行变换, 使得中间结果趋近于可行域中心, 提高收敛速度.

最优性条件

原问题和对偶问题的最优性条件方程为：

$$Ax = b$$

$$A^T y + s = c$$

$$x_i s_i = 0, (i = 1, \dots, n), (x, s \geq 0)$$

重写为如下形式：

$$F_0(x, y, s) = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, x \geq 0, s \geq 0.$$

$$X = \text{Diag}(x).$$

内点条件定义

定义：内点条件

原问题和对偶问题满足内点条件，当且仅当原问题和对偶问题都存在严格可行解，即 $\mathcal{F}_P^0 \neq \emptyset, \mathcal{F}_D^0 \neq \emptyset$.

内点条件定义

定义：内点条件

原问题和对偶问题满足内点条件，当且仅当原问题和对偶问题都存在严格可行解，即 $\mathcal{F}_P^0 \neq \emptyset, \mathcal{F}_D^0 \neq \emptyset$.

当且仅当原问题和对偶问题都存在严格可行解时，“原问题-对偶问题”满足内点条件。

原问题的对数障碍函数定义

定义

原问题的对数障碍函数为

$$\Phi_{\mu}(x) = c^T x - \mu \sum_{i=1}^n \log(x_i) \quad (1)$$

其中, $\mu > 0$, x 为所有的正数可行解. $\Phi_{\mu}(x)$ 的可行域为 $\mathcal{F}_P^0$. μ 称为障碍参数.

原问题的对数障碍函数性质

性质

原问题的对数障碍函数是严格凸函数.

原问题的对数障碍函数性质

性质

原问题的对数障碍函数是严格凸函数.

证明: Φ_μ 的梯度为

$$\nabla \Phi_\mu(x) = c - \mu X^{-1}e$$

$$e = (1, 1, \dots, 1)^T.$$

原问题的对数障碍函数性质

性质

原问题的对数障碍函数是严格凸函数.

证明: Φ_μ 的梯度为

$$\nabla \Phi_\mu(x) = c - \mu X^{-1}e$$

$$e = (1, 1, \dots, 1)^T.$$

黑塞矩阵为

$$\nabla^2 \Phi_\mu(x) = \mu X^{-2}$$

对于 $x \in \mathcal{F}_P^0$, 黑塞矩阵正定。说明 Φ_μ 在 $\mathcal{F}_P^0$ 上是严格凸函数.

对偶问题的对数障碍函数

定义：对偶问题的对数障碍函数

对偶问题的对数障碍函数为

$$\tilde{\Phi}_{\mu}(y) = b^T y + \mu \sum_{i=1}^n \log(c_i - a_i^T y) \quad (2)$$

$a_i, i = 1, 2, \dots, n$ 表示矩阵 A 的各列向量. $\tilde{\Phi}_{\mu}(y)$ 的可行域为 $\mathcal{F}_D^0$.

对偶问题的对数障碍函数

对偶问题的对数障碍函数是严格凹的.

对偶问题的对数障碍函数

对偶问题的对数障碍函数是严格凹的. 证明: $\tilde{\Phi}_\mu$ 的梯度和黑塞矩阵为

$$\begin{aligned}\nabla \tilde{\Phi}_\mu(y) &= b - \mu \sum_{i=1}^n \frac{a_i}{c_i - a_i^T y} \\ \nabla^2 \tilde{\Phi}_\mu(y) &= -\mu \sum_{i=1}^n \frac{a_i a_i^T}{(c_i - a_i^T y)^2}\end{aligned}$$

对偶问题的对数障碍函数

对偶问题的对数障碍函数是严格凹的. 证明: $\tilde{\Phi}_\mu$ 的梯度和黑塞矩阵为

$$\begin{aligned}\nabla \tilde{\Phi}_\mu(y) &= b - \mu \sum_{i=1}^n \frac{a_i}{c_i - a_i^T y} \\ \nabla^2 \tilde{\Phi}_\mu(y) &= -\mu \sum_{i=1}^n \frac{a_i a_i^T}{(c_i - a_i^T y)^2}\end{aligned}$$

由于 $\text{rank}(A) = m$, 对于任意的 $z \neq 0$, 至少存在一个 i 满足 $a_i^T z \neq 0$. 因此, 对于任意 $z \neq 0$,

$$z^T \nabla^2 \tilde{\Phi}_\mu(y) z = -\mu \sum_{i=1}^n \frac{(a_i^T z)^2}{(c_i - a_i^T y)^2} < 0$$

这说明 $\tilde{\Phi}_\mu$ 是 $\mathcal{F}_D^0$ 上的严格凹函数。

内点条件定理

令 $\mu > 0$, 则如下表达式等价:

- 1 $\mathcal{F}_P^0$ 和 $\mathcal{F}_D^0$ 非空.
- 2 Φ_μ 在定义域 $\mathcal{F}_P^0$ 存在惟一的最小值.
- 3 $\tilde{\Phi}_\mu$ 在定义域 $\mathcal{F}_D^0$ 存在惟一的极大值.
- 4 方程

$$F_\mu(x, y, s) = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs - \mu e \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, x \geq 0, s \geq 0. \quad (3)$$

有惟一解.

如果(1)到(4)成立, 则 $\Phi(\mu)$ 最小值对应的 $x(\mu)$ 和 $\tilde{\Phi}_\mu$ 极大值对应的 $y(\mu)$ 恰好是式(3)的解: $(x(\mu), y(\mu), s(\mu)), s(\mu) = c - A^T y(\mu)$.

内点条件定理

由于 $x_i s_i = \mu, i = 1, 2, \dots, n$, 因此方程(3)的解满足 $x > 0$ 和 $s > 0$. 这意味着 $x > 0$ 和 $s > 0, y$ 分别是原问题和对偶问题的严格可行解。第三个方程称为**趋中条件**.

内点条件不一定总能够得到满足. 接下来需要增加如下假设:

原问题和对偶问题都存在严格可行解, 即 $\mathcal{F}_P^0 \neq \emptyset$, $\mathcal{F}_D^0 \neq \emptyset$

中间路径的引出

求解如下最优性条件，可得原问题和对偶问题的最优解：

$$F_0(x, y, s) = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, x \geq 0, s \geq 0.$$

中间路径的引出

可利用牛顿法进行求解:

$$\begin{pmatrix} x^{(k+1)} \\ y^{(k+1)} \\ s^{(k+1)} \end{pmatrix} = \begin{pmatrix} x^k \\ y^k \\ s^k \end{pmatrix} - DF_0(x^k, y^k, s^k)^{-1} \cdot F_0(x^k, y^k, s^k)$$

DF_0 表示 F_0 的Jacobi矩阵

$$DF_0(x, y, s) = \begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \quad (4)$$

中间路径的引出

解的特性

满足最优性条件的解都满足 $x_i s_i = 0 (i = 1, 2, \dots, n)$,
即位于“P-D”可行解的边界上:

$$\mathcal{F} = \{(x, y, s) \in \mathbb{R}_+^n \times \mathbb{R}^m \times \mathbb{R}_+^n \mid Ax = b, A^T y + s = c\}$$

严格P-D可行解按以下方式进行定义

$$\mathcal{F}^0 = \{(x, y, s) \in \mathbb{R}_{++}^n \times \mathbb{R}^m \times \mathbb{R}_{++}^n \mid Ax = b, A^T y + s = c\}$$

中间路径的引出

当Jacobian矩阵可逆时，利用牛顿法可以很容易的迭代计算解 (x, y, s) 。什么情况下，Jacobi矩阵才是非奇异的呢？

中间路径的引出

当Jacobian矩阵可逆时，利用牛顿法可以很容易的迭代计算解 (x, y, s) 。什么情况下，Jacobi矩阵才是非奇异的呢？

Jacobian非奇异定理

当 $x > 0$ 和 $s > 0$ 时，Jacobi矩阵非奇异。

中间路径的引出

当Jacobian矩阵可逆时，利用牛顿法可以很容易的迭代计算解 (x, y, s) 。什么情况下，Jacobi矩阵才是非奇异的呢？

Jacobian非奇异定理

当 $x > 0$ 和 $s > 0$ 时，Jacobi矩阵非奇异。

而最优性条件方程的解满足 $x_i s_i = 0$ ，因此，它并不能保证Jacobi矩阵一直都是非奇异的。那么应该怎么办呢？

中间路径的引出

当Jacobian矩阵可逆时，利用牛顿法可以很容易的迭代计算解 (x, y, s) 。什么情况下，Jacobi矩阵才是非奇异的呢？

Jacobian非奇异定理

当 $x > 0$ 和 $s > 0$ 时，Jacobi矩阵非奇异。

而最优性条件方程的解满足 $x_i s_i = 0$ ，因此，它并不能保证Jacobi矩阵一直都是非奇异的。那么应该怎么办呢？

一种最为直接的思路是放松对 $x_i s_i = 0$ 的要求，即求解方程(3).

中间路径的引出

对于满足方程(3)的任意 (x, y, s) , 都有 $x_i s_i = \mu > 0$ 成立, 这意味着 $x > 0, s > 0$. 接下来可利用牛顿法来求解方程(3):

$$\mathbf{x}(\mu) = (x(\mu), y(\mu), s(\mu))$$

中间路径定义

集合

$$\mathcal{C} = \{\mathbf{x}(\mu) | \mu > 0\}$$

称为中间路径.

对偶间隙

$x(\mu)$ 和 $y(\mu)$ 之间的对偶间隙定义为：

$$c^T x(\mu) - b^T y(\mu)$$

当 x^* 和 y^* 分别是线性优化问题的原问题和对偶问题的最优解时，对偶间隙为零。

对偶间隙

$x(\mu)$ 和 $y(\mu)$ 之间的对偶间隙定义为:

$$c^T x(\mu) - b^T y(\mu)$$

当 x^* 和 y^* 分别是线性优化问题的原问题和对偶问题的最优解时, 对偶间隙为零。

$$n\mu = \sum_{i=1}^n x_i(\mu)s_i(\mu) = x^T(\mu)s(\mu) = c^T x(\mu) - b^T y(\mu)$$

归一化的对偶间隙定义为

$$\mu = (c^T x(\mu) - b^T y(\mu))/n$$

这给出了 $x(\mu)$ 和 $y(\mu)$ 离着最优解有多远的一个测度. 随着 $\mu \rightarrow 0$, $c^T x(\mu)$ 和 $b^T y(\mu)$ 互相趋近.

示例

原问题：

$$\begin{aligned} -x_1 - 3x_2 - 4x_3 &\rightarrow \min \\ x_1 + x_2 + x_3 &= 1, x \geq 0 \end{aligned}$$

对偶问题：

$$\begin{aligned} y &\rightarrow \max \\ y + s_1 &= -1 \\ y + s_2 &= -3 \\ y + s_3 &= -4 \\ s &\geq 0 \end{aligned}$$

示例

松弛的最优性条件:

$$x_1 + x_2 + x_3 = 1$$

$$y + s_1 + 1 = 0$$

$$y + s_2 + 3 = 0$$

$$y + s_3 + 4 = 0$$

$$x_i s_i = \mu$$

求解后可得

$$\frac{1}{\mu} = -\left(\frac{1}{1+y} + \frac{1}{3+y} + \frac{1}{4+y}\right)$$

$$x_1 = \frac{\mu}{-1-y}$$


$$x_2 = \frac{\mu}{-3-y}$$

$$x_3 = \frac{\mu}{-4-y}$$

求中间路径的MATLAB代码

```
mu=5:-0.01:0.01;
mu_length=length(mu);
for i=1:mu_length
    b=mu(i);
    x=fsolve(...
        @(x) 1/b+1/(1+x)+1/(3+x)+1/(4+x), -4.5, ...
        optimset('Display','off'));
    y(i)=x;
    x1(i)=b/(-1-y(i));
    x2(i)=b/(-3-y(i));
    x3(i)=b/(-4-y(i));
end
comet3(x1,x2,x3)
```

示例



利用牛顿法求解最优性条件

首先必须求解松弛的最优性条件:

$$F_{\mu}(x, y, s) = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs - \mu e \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, x \geq 0, s \geq 0 \quad (5)$$

全步长牛顿法的迭代公式:

$$(x^+, y^+, s^+) = (x, y, s) - (\Delta x, \Delta y, \Delta s)$$

牛顿法的搜索方向

牛顿法的搜索方向 $\Delta \mathbf{x}$ 可通过下式求得

$$DF_{\mu}(\mathbf{x})\Delta \mathbf{x} = F_{\mu}(\mathbf{x})$$

$\mathbf{x} = (x, y, s), \Delta \mathbf{x} = (x, y, s) - (x^+, y^+, s^+) = (\Delta x, \Delta y, \Delta s)$.

当 $\mu > 0$, 定义 r_d 为对偶残差, r_p 为原残差, r_c 为辅助残差:

$$r_d = A^T y + s - c; r_p = Ax - b; r_c = Xs - \mu e$$

$\mathbf{x}$ 处的牛顿法方向 $\Delta \mathbf{x}$ 为

$$DF_{\mu}(\mathbf{x})\Delta \mathbf{x} = (r_d, r_p, r_c) = F_{\mu}(\mathbf{x}) \quad (6)$$

牛顿法搜索方向

将 DF_μ 代入方程(6):

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} r_d \\ r_p \\ r_c \end{pmatrix} \quad (7)$$

在 DF_μ 的最后一行左乘 S^{-1} :

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ I & 0 & S^{-1}X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} r_d \\ r_p \\ S^{-1}r_c \end{pmatrix} \quad (8)$$

对称化之后的Jacobian矩阵很容易求逆，在此基础上可以推导出Newton方向的求解公式。

牛顿法搜索方向

搜索方向

方程(7)的解为:

$$\Delta y = (AXS^{-1}A^T)^{-1}(r_p - AS^{-1}(r_c - Xr_d))$$

$$\Delta s = r_d - A^T \Delta y$$

$$\Delta x = S^{-1}(r_c - X\Delta s)$$

确定了方向之后，与无约束非线性规划的求解过程类似，接下来可以确定一个合适的步长 α ，得到

$$(x^+, y^+, s^+) = (x, y, s) - \alpha(\Delta x, \Delta y, \Delta s)$$

使得 $(x^+, s^+) > 0$.

对偶测度

对于 $(x, y, s) \in \mathcal{F}^0$ ，定义**对偶测度** τ ：

$$\tau = \frac{1}{n} \sum_{i=1}^n x_i s_i = \frac{1}{n} x^T s$$

对偶测度给出的是 x_i 和 s_i 乘积的平均值。如果 x_i 和 s_i 都位于中间路径上，则 $\mu = \tau$ 成立，但是， x_i 和 s_i 不一定在中间路径上，也就是说，在很多情况下， $\tau \neq \mu$ 。

新的最优性条件

我们可以定义一个新的最优性条件。首先定义一个趋中参数 $\sigma \in [0, 1]$ ，以此可得：

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ XSe - \sigma\tau e \end{pmatrix} \quad (9)$$

由此得到的牛顿法方向 $(\Delta x, \Delta y, \Delta s)$ 趋向于一个新的值 $(x_{\sigma,\tau}, y_{\sigma,\tau}, s_{\sigma,\tau}) \in \mathcal{C}$ ，其中， $\sigma\tau = \mu$ 。

内点法的总体思路

Step 1: 指定搜索的起始点 $(x^{(0)}, y^{(0)}, s^{(0)}) \in \mathcal{F}^0$ 和精度阈值 $\epsilon > 0$.

Step 2: 初始化 $(x, y, s) = (x^{(0)}, y^{(0)}, s^{(0)})$, $\tau = \frac{1}{n}x^T s$.

Step 3: 如果 $\tau > \epsilon$, 求解(9), 其中 $\sigma \in [0, 1]$.

Step 4: 令 $(x, y, s) = (x, y, s) - \alpha(\Delta x, \Delta y, \Delta s)$, 其中 $\alpha \in (0, 1]$ 表示一个适当的步长, 使得 $(x, s) > 0$.

Step 5: 计算 $\tau = \frac{1}{n}x^T s$.

内点法的总体思路

内点法有如下特性

- 1 σ 和 α 取值方式不同，对应着内点法的不同实现
- 2 $\sigma\tau$ 与最优性条件方程中参数 μ 的作用相同
- 3 当 $\sigma = 0$,直接指向使得最优性条件满足的点。这也被称为仿射尺度方向。
- 4 $\sigma = 1$,得到牛顿方向，指向 $(x_\tau, y_\tau, s_\tau) \in \mathcal{C}$ ，使得 $x_i s_i$ 等于 τ 。该方向被称为趋中方向。

内点法的总体思路

为了确定适当的步长, 选择 $\eta \in (0, 1)$, 比如 $\eta = 0.99$, 使得 $\eta \approx 1$, 并令

$$\alpha = \min\left\{1, \eta \min_{\Delta x_i > 0} \frac{x_i}{\Delta x_i}, \eta \min_{\Delta s_i > 0} \frac{s_i}{\Delta s_i}\right\}$$

具体实现方法

- 1 短步路径追踪方法
- 2 Mizuno-Todd-Ye预估-校正方法
- 3 长步路径追踪方法
- 4 Mehrotra预估-校正方法

接下来，我们将只介绍Mehrotra预估-校正方法，在MATLAB中，也利用该方法来求解线性规划。

Mehrotra预估-校正方法基本思路

预估-校正方法在一次迭代中分为两个阶段，首先预估一个搜索方向；然后对这个搜索方向进行校正，以校正后的方向作为该阶段的搜索方向。相对于其他内点法，预估-校正方法的最大优点在于初始点的选择方面。绝大部分内点法都需要将初始点设定为严格内点，整个迭代过程也是在原问题-对偶问题的严格可行域内进行。实际上，初始点为严格内点这一要求是很难实现的。预估-校正方法可以回避这一问题，它对初始点 $(x^{(0)}, y^{(0)}, s^{(0)})$ 的选择不存在严格内点的要求，只需要满足 $(x^{(0)}, s^{(0)}) > 0$ 即可。这就极大地方便了求解过程。

预估步骤

求解

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x^N \\ \Delta y^N \\ \Delta s^N \end{pmatrix} = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs \end{pmatrix} = \begin{pmatrix} r_d \\ r_p \\ r_c \end{pmatrix} \quad (10)$$

$(\Delta x^N, \Delta y^N, \Delta s^N)$ 表示 **仿射尺度** 或牛顿方向. 接下来可通过设定

$$\alpha_p^N = \min\{1, \min_{\Delta x_i^N > 0} \frac{x_i}{\Delta x_i^N}\}, \alpha_d^N = \min\{1, \min_{\Delta s_i^N > 0} \frac{s_i}{\Delta s_i^N}\},$$

计算最大步长 $\alpha_p^N, \alpha_d^N \in (0, 1]$ 使得

$$x(\alpha_p^N) = x - \alpha_p^N \Delta x^N \geq 0, s(\alpha_d^N) = s - \alpha_d^N \Delta s^N \geq 0$$

计算趋中参数

与其他方法相比，预估-校正方法的另外一个特点是趋中参数 σ 可以随着迭代过程中进行自适应的进行调整。具体调整方式为：在预估阶段获得了 $x(\alpha_p^N)$ 和 $s(\alpha_d^N)$ 之后，首先计算

$$\tau^N = \frac{1}{n} x(\alpha_p^N)^T s(\alpha_d^N)$$

其中， τ 是通过本次迭代点 (x, y, s) 得到的。接下来按照下式计算趋中参数 σ

$$\sigma = \left(\frac{\tau^N}{\tau} \right)^3$$

计算趋中参数

与其他方法相比，预估-校正方法的另外一个特点是趋中参数 σ 可以随着迭代过程中进行自适应的进行调整。具体调整方式为：在预估阶段获得了 $x(\alpha_p^N)$ 和 $s(\alpha_d^N)$ 之后，首先计算

$$\tau^N = \frac{1}{n} x(\alpha_p^N)^T s(\alpha_d^N)$$

其中， τ 是通过本次迭代点 (x, y, s) 得到的。接下来按照下式计算趋中参数 σ

$$\sigma = \left(\frac{\tau^N}{\tau} \right)^3$$

如果 σ 的值比较小，说明什么问题？

校正步骤

求解方程

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs - \sigma \tau e \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ \Delta X^N \Delta s^N \end{pmatrix} \quad (11)$$

得到方向 $(\Delta x, \Delta y, \Delta s)$. 通过选择 $\eta \approx 1$, 如 $\eta = 0.99$, 确定最大步长.

$$\alpha_p = \min\left\{1, \eta \min_{\Delta x_i > 0} \frac{x_i}{\Delta x_i}\right\}, \alpha_d = \min\left\{1, \eta \min_{\Delta s_i > 0} \frac{s_i}{\Delta s_i}\right\}$$

校正步骤

求解方程

$$\begin{pmatrix} 0 & A^T & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} \Delta x \\ \Delta y \\ \Delta s \end{pmatrix} = \begin{pmatrix} A^T y + s - c \\ Ax - b \\ Xs - \sigma \tau e \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ \Delta X^N \Delta s^N \end{pmatrix} \quad (11)$$

得到方向 $(\Delta x, \Delta y, \Delta s)$. 通过选择 $\eta \approx 1$, 如 $\eta = 0.99$, 确定最大步长.

$$\alpha_p = \min\left\{1, \eta \min_{\Delta x_i > 0} \frac{x_i}{\Delta x_i}\right\}, \alpha_d = \min\left\{1, \eta \min_{\Delta s_i > 0} \frac{s_i}{\Delta s_i}\right\}$$

最后, 确定新的迭代点 $(x, y, s) = (x - \alpha_p \Delta x, y - \alpha_d \Delta y, s - \alpha_d \Delta s)$.

Mehrotra预估-校正方法的算法步骤

给定 $(x^{(0)}, y^{(0)}, s^{(0)})$, $(x^{(0)}, s^{(0)}) > 0$, 精度阈值 $\epsilon > 0$ 。初始化 $(x, y, s) = (x^{(0)}, y^{(0)}, s^{(0)})$, $\tau = \frac{1}{n}x^T s$ 。

当 $\max(\tau, \|Ax - b\|, \|A^T y + s - c\|) > \epsilon$

预估步

求解(10), 得到 $(\Delta x^N, \Delta y^N, \Delta s^N)$. 计算最大可能的步长 $\alpha_p^N, \alpha_d^N, \tau^N$. 令 $\sigma = (\frac{\tau^N}{\tau})^3$.

校正步

求解(11) 得到 $(\Delta x, \Delta y, \Delta s)$. 计算两个步长 α_p 和 α_d . 令 $(x, y, s) = (x - \alpha_p \Delta x, y - \alpha_d \Delta y, s - \alpha_d \Delta s)$, $\tau = \frac{1}{n}x^T s$.

简介

在Matlab优化工具箱中，内点法用于求解规模较大的线性优化问题，比如存在几十个决策变量的问题。Matlab中所使用的内点法基本上是以预估-校正方法为基础，进行了简单的修改和调整。

Matlab中所定义的线性规划问题模型在单纯形法中已经介绍过了，所使用的求解函数仍为linprog，调用方式在前面也已经介绍过了。为了明确指定采用单纯形法进行求解，只需要对linprog函数中的options参数进行设置即可。

```
ops=optimset('LargeScale','on')
```

即明确指定这是一个大规模问题，否则Matlab会自行判断。

示例：问题描述

Matlab中给出了一个优化问题模型，在该模型中，共有48 个决策变量，30个不等式约束，20 个等式约束。为了定义方便，Matlab将模型参数定义为一个数据文件sc50b.mat，使用之前直接载入工作空间即可。具体代码为：

```
load sc50b
ops=optimset('Largescale','on','Display','iter');
[x,fval,exitflag,output] = ...
    linprog(f,A,b,Aeq,beq,lb,[],[],ops);
```

需要指出的是，此处没有指定算法的精度，因此，精度将采用默认值 $1e-8$ 。

示例: 结果

计算结果为

Residuals:		Primal Infeas $A \cdot x - b$	Dual Infeas $A' \cdot y + z - f$	Duality Gap $x' \cdot z$	Total Rel Error

Iter	0:	1.50e+003	2.19e+001	1.91e+004	1.00e+002
Iter	1:	1.15e+002	2.37e-015	3.62e+003	9.90e-001
Iter	2:	1.61e-012	2.62e-015	4.32e+002	9.48e-001
Iter	3:	3.11e-012	4.26e-015	7.78e+001	6.88e-001
Iter	4:	4.75e-011	6.01e-016	2.38e+001	2.69e-001
Iter	5:	3.68e-010	4.41e-016	5.05e+000	6.89e-002
Iter	6:	1.08e-010	2.29e-016	1.64e-001	2.34e-003
Iter	7:	7.07e-012	1.86e-016	1.09e-005	1.55e-007
Iter	8:	1.47e-012	1.72e-016	1.09e-011	1.55e-013

Optimization terminated.

总结

- 1 内点条件
 - ▶ 严格内点条件
 - ▶ 松弛内点条件
- 2 求解内点条件的Newton法
- 3 预估-校正方法

作业

认真看PPT，掌握内点法的精神实质，以及利用MATLAB调用内点法求解线性优化问题的过程。