

最优化技术

孙志强

第五章 有约束非线性优化问题

内容

- 1 5.1 预备知识
- 2 5.2 只含等式约束的非线性优化问题
- 3 5.3 含有等式和不等式约束的优化问题
- 4 5.4 习题和示例
- 5 总结

引言

到目前为止，我们已经学习了

- ① 优化问题的最优性条件
 - ▶ 一二阶必要条件
 - ▶ 二阶充分条件
- ② 无约束非线性规划的求解方法(迭代的基本思路)
- ③ 线性规划的求解方法
 - ▶ 单纯形法
 - ▶ 内点法(预估-校正方法)

引言

到目前为止，我们已经学习了

- ① 优化问题的最优性条件
 - ▶ 一二阶必要条件
 - ▶ 二阶充分条件
- ② 无约束非线性规划的求解方法(迭代的基本思路)
- ③ 线性规划的求解方法
 - ▶ 单纯形法
 - ▶ 内点法(预估-校正方法)

世界本质上是非线性的，无约束的问题很少见，有约束的非线性规划问题更有实际意义。前面的这些内容将成为接下来学习的基础。

有约束非线性优化问题的结构

有约束非线性优化问题：

$$\begin{cases} f(x) \rightarrow \min \\ g_i(x) \leq 0 \quad \text{for } i \in \mathcal{I} \\ h_j(x) = 0 \quad \text{for } j \in \mathcal{E} \end{cases}$$

有约束非线性优化问题的结构

有约束非线性优化问题：

$$\begin{cases} f(x) \rightarrow \min \\ g_i(x) \leq 0 \quad \text{for } i \in \mathcal{I} \\ h_j(x) = 0 \quad \text{for } j \in \mathcal{E} \end{cases}$$

若只考虑等式约束：

$$\begin{cases} f(x) \rightarrow \min \\ h_j(x) = 0 \quad \text{for } j \in \mathcal{E} \end{cases}$$

问题描述

等式约束 $h(x) = [h_1, h_2, \dots, h_m]^T$, 故有

$$x \in \mathbb{R}^n, f: \mathbb{R}^n \rightarrow \mathbb{R}, h: \mathbb{R}^n \rightarrow \mathbb{R}^m, m < n$$

假定函数 h 连续可微, 即 $h \in \mathcal{C}^1$.

正则点

正则点定义

满足 $h_1(x^*) = 0, h_2(x^*) = 0, \dots, h_m(x^*) = 0$, 且梯度向量 $\nabla h_1(x^*), \nabla h_2(x^*), \dots, \nabla h_m(x^*)$ 线性无关的点 x^* 称为约束的正则点.

正则点

正则点定义

满足 $h_1(x^*) = 0, h_2(x^*) = 0, \dots, h_m(x^*) = 0$, 且梯度向量 $\nabla h_1(x^*), \nabla h_2(x^*), \dots, \nabla h_m(x^*)$ 线性无关的点 x^* 称为约束的正则点.

$Dh(x^*)$ 表示函数 $h = [h_1, h_2, \dots, h_m]^T$ 在 x^* 处的 Jacobi 矩阵

$$Dh(x^*) = \begin{bmatrix} Dh_1(x^*) \\ \vdots \\ Dh_m(x^*) \end{bmatrix} = \begin{bmatrix} \nabla h_1(x^*)^T \\ \vdots \\ \nabla h_m(x^*)^T \end{bmatrix}$$

x^* 是正则点, 当且仅当 $\text{rank}(Dh(x^*)) = m$.

切空间

平面 $S = \{x \in \mathbb{R}^n | h(x) = 0\}$ 在 x^* 处的切空间为

$$T(x^*) = \{y | Dh(x^*)y = 0\}$$

切空间 $T(x^*)$ 是矩阵 $Dh(x^*)$ 的零空间

$$T(x^*) = \mathcal{N}(Dh(x^*))$$

x^* 处的切平面为

$$TP(x^*) = T(x^*) + x^* = \{x + x^* | x \in T(x^*)\}$$



$\mathbb{R}^2$ 空间下的切空间和切平面

Figure: $\mathbb{R}^2$ 空间下的切空间和切平面

$\mathbb{R}^3$ 空间下的切空间和切平面

$\mathbb{R}^2$ 下的Lagrange定理

选择 $x^* = [x_1^*, x_2^*]^T$ 使得 $h(x^*) = 0, \nabla h(x^*) \neq 0$. 可以确定一个连续可微的向量函数 $x: \mathbb{R} \rightarrow \mathbb{R}^2$ 使得

$$\begin{aligned}x(t) &= [x_1(t), x_2(t)]^T, t \in (a, b) \\x^* &= x(t^*), \dot{x}(t^*) \neq 0, t^* \in (a, b)\end{aligned}$$

对于所有的 $t \in (a, b)$, $h(x(t)) = 0$,

$$\frac{d}{dt}h(x(t)) = \nabla h(x(t))^T \dot{x}(t) = 0$$

即 $\nabla h(x^*)$ 正交于 $\dot{x}(t^*)$.

$\mathbb{R}^2$ 下的Lagrange条件

x^* 是 $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ 在约束 $\{x|h(x) = 0\}$ 下的最优解. 复合函数 $\psi(t) = f(x(t))$ 在 t^* 处达到最小值. 无约束优化问题的一阶必要条件告诉我们

$$\frac{d\psi}{dt}(t^*) = 0$$

利用链式规则

$$\frac{d\psi}{dt}(t^*) = \nabla f(x(t^*))^T \dot{x}(t^*) = \nabla f(x^*)^T \dot{x}(t^*) = 0$$

$\nabla f(x^*)$ 正交于 $\dot{x}(t^*)$.

$\mathbb{R}^2$ 下的Lagrange条件

$\nabla f(x^*)$ 和 $\nabla h(x^*)$ 都与 $\dot{x}(t)$ 正交，这说明两者之间保持“平行”，即

$$\nabla f(x^*) = \lambda \nabla h(x^*)$$

Lagrange条件($n=2, m=1$), 定理19.2

x^* 为 $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ 在约束 $h(x) = 0, h : \mathbb{R}^2 \rightarrow \mathbb{R}$ 下的最优解. 那么 $\nabla f(x^*), \nabla h(x^*)$ 平行. 即如果 $\nabla h(x^*) \neq 0$, 存在一个 λ^* 使得

$$\nabla f(x^*) + \lambda^* \nabla h(x^*) = 0$$

通用的Lagrange定理

$f : \mathbb{R}^n \rightarrow \mathbb{R}, h : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 下的Lagrange定理.

拉格朗日定理, 定理19.3

x^* 为 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 在约束


$$h(x) = 0, h : \mathbb{R}^n \rightarrow \mathbb{R}^m (m \leq n)$$

下的最优解. 如果 x^* 为正则点, 存在 $\lambda^* \in \mathbb{R}^m$ 使得


$$Df(x^*) + \lambda^{*T} Dh(x^*) = 0^T$$

λ^* 为Lagrange乘子。


Lagrange定理示意



Lagrange定理示意




(a)




(b)

Figure: (a)极大值; (b)极小值

Lagrange定理示意




(c)



(d)

Figure: (c)极大值; (d)非极值

Lagrange定理示意



Lagrange方程

Lagrange方程为 $l : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$:

$$l(x, \lambda) \triangleq f(x) + \lambda^T h(x)$$

局部极小值 x^* 的Lagrange条件可以写为Lagrange方程的形式

$$Dl(x^*, \lambda^*) = 0^T$$

$$D_x l(x, \lambda) = 0^T$$

$$D_\lambda l(x, \lambda) = 0^T$$

示例

考虑如下的约束求极值问题：

目标函数为

$$f(x) = x_1^2 + x_2^2$$

可行域为一个椭圆

$$\{[x_1, x_2]^T : h(x) = x_1^2 + 2x_2^2 - 1 = 0\}$$

示例

$$\begin{cases} x^T Q x \rightarrow \max \\ x^T P x = 1 \end{cases}$$

二阶必要条件

二阶必要条件, 定理19.4

x^* 是 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ 在约束 $h(x) = 0, h : \mathbb{R}^n \rightarrow \mathbb{R}^m, m < n$ 下的最优解, 且 $f, h \in C^2$. 如果 x^* 是正则点, 存在 $\lambda^* \in \mathbb{R}^m$ 使得

① $Df(x^*) + \lambda^{*T} Dh(x^*) = 0^T;$

② 对于所有 $y \in T(x^*)$, 有 $y^T L(x^*, \lambda^*) y \geq 0$

$L(x, \lambda) = F(x) + [\lambda H(x)]$, $F(x)$ 为 f 的黑塞矩阵.

$$[\lambda H(x)] = \lambda_1 H_1(x) + \dots + \lambda_m H_m(x)$$

$H_i(x)$ 是 $h_i(x)$ 的黑塞矩阵.

二阶充分条件

定理19.5

$f, h \in \mathcal{C}^2$, 存在 $x^* \in \mathbb{R}^n, \lambda^* \in \mathbb{R}^m$ 使得

① $Df(x^*) + \lambda^{*T} Dh(x^*) = 0^T$;

② 对于所有的 $y \in T(x^*), y \neq 0$, 有 $y^T L(x^*, \lambda^*) y > 0$

x^* 是 f 的严格局部极小值.

起作用约束

$$\begin{cases} f(x) \rightarrow \min \\ g_i(x) \leq 0 \quad \text{for } i \in \mathcal{I} \\ h_j(x) = 0 \quad \text{for } j \in \mathcal{E} \end{cases}$$

定义

如果 $g_i(x^*) = 0$, 则不等式约束 $g_i(x) \geq 0$ 称为起作用约束; 否则为不起作用约束. x^* 为最优解.

等式约束是天然的起作用约束.

起作用约束集

如果 $h(x^*) = 0, g(x^*) \leq 0$, 令 $I(x^*)$ 表示所有起作用不等式约束的下标集

$$I(x^*) := \{i : g_i(x^*) = 0\}$$

如果

$$\nabla h_j(x^*), \nabla g_i(x^*), j \in \mathcal{E}, i \in I(x^*)$$

线性无关, 则 x^* 是一个正则点.

Karush-Kuhn-Tucker条件

KKT定理,定理20.1

$f, h, g \in C^1$, x^* 为 f 在约束 $h(x) = 0, g(x) \leq 0$ 下的最优解, 且为正则点. 则存在 $\lambda^* \in \mathbb{R}^m, \mu^* \in \mathbb{R}^p$ 使得


① $\mu^* \geq 0$;

② $Df(x^*) + \lambda^{*T} Dh(x^*) + \mu^{*T} Dg(x^*) = 0^T$;

③ $\mu^{*T} g(x^*) = 0$

λ^* 为Lagrange乘子向量, μ^* 为KKT乘子向量. KKT定理意味着对于 $i \notin I(x^*)$, 有 $\mu_i^* = 0$.

Karush-Kuhn-Tucker条件示意



示例

目标函数为 $f(x) = \frac{1}{2} \|Ax - b\|^2$ ，求最小值。约束为

$$x_1 + x_2 + \dots + x_n = 1$$

$$x_1, x_2, \dots, x_n \geq 0$$

a) 列写出KKT方程；

b) 对于这一问题，正则点意味着什么？是否能够找到一个可行的非正则点？

二阶必要条件,定理20.2

$f, h, g \in \mathcal{C}^2$, x^* 为 f 在约束 $h(x) = 0, g(x) \leq 0$ 下的最优解, 且为正则点. 则存在 $\lambda^* \in \mathbb{R}^m, \mu^* \in \mathbb{R}^p$ 使得

- 1 $\mu^* \geq 0, Df(x^*) + \lambda^{*T} Dh(x^*) + \mu^{*T} Dg(x^*) = 0^T, \mu^{*T} g(x^*) = 0;$
- 2 对于所有的 $y \in T(x^*)$, 有 $y^T L(x^*, \lambda^*, \mu^*) y \geq 0$.

其中, $T(x^*)$ 是由起作用约束所定义平面的切空间, 即

$$T(x^*) = \{y \in \mathbb{R}^n : Dh(x^*)y = 0, Dg_i(x^*)y = 0, i \in I(x^*)\}$$

二阶充分条件,定理20.3

$f, g, h \in C^2$, 存在一个可行点 $x^* \in \mathbb{R}^n$ 和两组向量 $\lambda^* \in \mathbb{R}^m, \mu^* \in \mathbb{R}^p$, 使得

① $\mu^* \geq 0, Df(x^*) + \lambda^{*T} Dh(x^*) + \mu^{*T} Dg(x^*) = 0^T, \mu^{*T} g(x^*) = 0;$

② 对于所有 $y \in \tilde{T}(x^*, \mu^*), y \neq 0$, 有 $y^T L(x^*, \lambda^*, \mu^*) y > 0$.

x^* 是 f 在约束 $h(x) = 0, g(x) \leq 0$ 下的严格局部极小值, 其中

$$\tilde{T}(x^*, \mu^*) = \{y | Dh(x^*)y = 0, Dg_i(x^*)y = 0, i \in \tilde{I}(x^*, \mu^*)\},$$

$$\tilde{I}(x^*, \mu^*) = \{i | g_i(x^*) = 0, \mu_i^* > 0\}$$

示例1

目标函数为 $f(x) = x_1^2 + x_2^2$ ，求最小值。约束为

$$x_1 \geq 0$$

$$x_2 \geq 0$$

$$x_1 + x_2 \geq 5$$

示例2


目标函数为 $f(x) = (x_1 - 1)^2 + x_2 - 2$ ，约束为

$$h(x) = x_2 - x_1 - 1 = 0,$$

$$g(x) = x_1 + x_2 - 2 \leq 0$$

利用KKT定理进行求解.

示例2



习题21.10

有如下优化问题：

$$\begin{cases} \frac{1}{2} \|x - x_0\|^2 \rightarrow \min \\ g(x) \leq 0 \end{cases}$$

$x \in \mathbb{R}^n$ ，函数 $g(x)$ 一阶可导，且有 $g(x_0) > 0$ 。如果该问题的最优解为 x^* ，利用KKT定理判断下列式子是否成立。

(1) $g(x^*) < 0$

(2) $g(x^*) = 0$

(3) $(x - x_0)^T \nabla g(x^*) < 0$

(4) $(x - x_0)^T \nabla g(x^*) = 0$

(5) $(x - x_0)^T \nabla g(x^*) > 0$

习题20.19

考虑以下优化问题：

$$\begin{cases} f(x) = x_1^2 + (x_2 + 1)^2 \rightarrow \min \\ x_2 \geq \exp(x_1) \end{cases}$$

$x_1, x_2 \in \mathbb{R}$ 。如果该问题的最优解为 $x^* = [x_1^*, x_2^*]^T$,

(1) 写出该优化问题的KKT条件；

(2) 证明 $x_2^* = \exp(x_1^*)$ ；

(3) 证明 $-2 < x_1^* < 0$ 。

总结

- 1 有关定义
 - ▶ 正则点
 - ▶ 切空间和切平面
- 2 纯等式约束下非线性优化问题的最优性条件
 - ▶ Lagrange定理(一阶必要条件)
 - ▶ 二阶必要条件和二阶充分条件
- 3 同时含等式和不等式约束下非线性优化问题的最优性条件
 - ▶ KKT定理(一阶必要条件。注意：当优化问题为凸优化，即目标函数为凸函数且可行域为凸集时，KKT条件就是充要条件)
 - ▶ 二阶必要条件和二阶充分条件

作业

1 19.2

2 20.8